

专题 7 文本信息检索任务

本专题将提供一份文档以及查询的数据，其中包括对查询-文档相关性的标注（0 代表不相关，1 代表相关）用于文本信息检索。本任务提供三种解决思路：

- (1) 用 TF-IDF 实现信息检索；
- (2) 用预训练模型 BERT 实现信息检索；
- (3) 用大语言模型（如 LLaMA 或者 Mistral）实现信息检索。

最终的评价指标采用 $MRR@5$ （主要的）、 $MRR@100$ 、 $MAP@5$ 、 $MAP@100$ 。

同学们可以将结果处理成以下形式，每行结果包含 5 列，用制表符或者空格分割。然后安装工具包 `pytrec_eval` 进行评价。。

QueryID DocumentID ranknumber scores yourmodelname

评价工具（不是每个评价指标都有，可自行修改）：

`pytrec_eval` 下载安装链接：https://github.com/cvangysel/pytrec_eval/tree/master

数据集链接(包含查询、相关性判断): document 为长文本检索, passage 为短文本检索
<https://microsoft.github.io/msmarco/TREC-Deep-Learning-2020>

专题 8 交互式信息检索任务

本任务属于多轮交互式检索，每组查询包括 10 条左右的查询语句，其中后面的查询可能包含前面查询的一些指代、隐含信息。以第一组查询为例，对于第 3 条查询“**What does it cost?**”，我们需要对“it”包含的语义进行补充，才能让模型明白用户的需求，返回正确的相关的文档。因此该任务的目的是，利用历史查询或者回复的信息对当前查询隐含的语义进行补充，使得最终的查询结果较好。

最终的评价指标采用 $MRR@5$ 、 $MRR@100$ 、 $MAP@5$ 、 $MAP@100$ 。

同学们可以将结果处理成以下形式，每行结果包含 5 列，用制表符分割。

QueryID DocumentID ranknumber scores yourmodelname

Number: 1

Title: career choice for Nursing and Physician's Assistant

Description: Considering career options for becoming a physician's assistant vs a nurse. Discussion topics include required education (including time, cost), salaries, and which is better overall.

- 1 What is a physician's assistant?
- 2 What are the educational requirements required to become one?
- 3 What does it cost?
- 4 What's the average starting salary in the UK?

- 5 What about in the US?
- 6 What school subjects are needed to become a registered nurse?
- 7 What is the PA average salary vs an RN?
- 8 What the difference between a PA and a nurse practitioner?
- 9 Do NPs or PAs make more?
- 10 Is a PA above a NP?
- 11 What is the fastest way to become a NP?
- 12 How much longer does it take to become a doctor after being an NP?

交互式检索的数据集，这里包括 4 年的任务，数据集有所不同，规模较大，也会增加一些子任务。建议同学们先尝试 2019 的挑战，同学们自行下载：

<https://github.com/daltonj/treccastweb#collection> ,

专题 9 跨模态图文信息检索任务

大规模预训练模型在 NLP 和 CV 领域得到广泛应用，本专题希望同学们能够了解当前主流的预训练模型，以 CLIP 为例实现跨模态检索任务。

对比语言-图像预训练模型（Contrastive Language-Image Pre-Training, CLIP）是一种基于多种（图像、文本）对进行训练的神经网络。在给定图像的情况下，它可以用自然语言来预测最相关的文本片段，而无需直接针对任务进行优化，类似于 GPT-2 和 gpt-3 的能力。我们发现 CLIP 在不使用任何原始的 1.28M 标记示例的情况下，在 ImageNet“零射击”上匹配原始 ResNet50 的性能，克服了计算机视觉中的几个主要挑战。（参考 <https://github.com/OpenAI/CLIP>）

除此之外，现在也有很多 CLIP 的变种，如 Chinese-CLIP，同学们都可以尝试。图文检索任务常用的数据集合为：MSCOCO 和 Flickr30K。本专题提供 Flickr30K 的下载链接。

Flickr30K 数据集包含 30,000 张图像及其对应的自然语言描述文本，压缩包大小通常较大（约几百 MB）。

通过网盘分享的文件：flickr30k

链接：<https://pan.baidu.com/s/1FL60y9lvh-sJf1pby4PRCQ?pwd=ncsq> 提取码：ncsq

专题 10 跨模态视频-文本检索任务

Ad-hoc 搜索任务的目标是对终端用户搜索用例进行建模，终端用户搜索用例（使用文本句子查询）来搜索包含人物、对象、活动、位置等的视频片段，以及这些内容的组合。2016 年至 2018 年采用了互联网档案馆（IACC.3）数据集，2019 年至 2021 年采用了基于 Vimeo 知识共享（V3C）数据集的新数据集（V3C1）。从 2022 年开始，该任务开始利用一个新的子集合 V3C2 在一组新的查询上测试系统，此外还使用公共（固定）进度查询集来度量 2022 年到 2024 年的系统进度。

给定的视频测试集（V3C2），主镜头边界参考，和一组文本特设查询（大约 30 个查询），对

于每个查询，返回一个最多包含 1000 个 shot id 的列表，这些 id 来自测试集合，根据它们包含目标查询的可能性进行排序。

将支持两个评估任务：每年有新查询的主任务，以及分别度量 2 年和 3 年系统进度的进度子任务。同学们可以选择任一年度的挑战任务作为实训。

欢迎同学们挑战，以下是任务主页面：

<https://www-nlpir.nist.gov/projects/tv2024/avs.html>

专题 10 任务型人机对话中的口语理解

问题描述：

任务型人机对话系统通常是针对某个特定领域而设计，在垂直领域内，意图和槽位的数量通常是有限的，并且是根据领域预定义好的。口语理解一般包含两个子任务：意图识别和槽填充。




图 1 口语理解输入输出样例

给定当前轮次用户的对话文本，意图识别任务识别用户的对话目的，其本质是对对话文本的分类；槽填充任务以填槽的方式抽取对话文本中包含的重要信息，可以抽象为对对话文本的序列标注问题。对于给定的对话文本序列 $X = \{x_1, x_2, x_3, \dots, x_n\}$ ，口语理解模块的主要任务是学习一个意图识别与槽填充联合模型 M ，通过 M 得到当前对话的意图 I 和每个词对应的槽位标签 $S = \{s_1, s_2, s_3, \dots, s_n\}$ ，如公式 1 所示：

$$\{I, S\} = M(X) \quad (\text{公式 1})$$

数据集：

ATIS 和 Snips 数据集是在口语理解研究中最广泛使用的数据集。ATIS 数据集包含用户在航空公司旅行系统上查询航班信息的记录, 数据集包含 17 类航班相关意图标签、84 类槽位标签, 训练集、验证集、测试集分别有 4478、500、893 条对话文本; Snips 数据集包含 Snips 私人语音助手项目收集得到的用户语音指令及其对应的人工标注, 相较于 ATIS 数据集更大更多样化, 数据集包含 7 类跨领域意图标签、40 类槽位标签, 训练集、验证集、测试集分别有 13084、700、700 条对话文本。

Snips 示例:

- *SearchCreativeWork*: 例如, “Find me the I, Robot television show。”
- *GetWeather*: 例如, “Is it windy in Boston, MA right now?”
- *BookRestaurant*: 例如, “I want to book a highly rated restaurant in Paris tomorrow night。”
- *PlayMusic*: 例如, “Play the last track from Beyoncé off Spotify。”
- *AddToPlaylist*: 例如, “Add Diamonds to my roadtrip playlist。”
- *RateBook*: 例如, “Give 6 stars to *Of Mice and Men*。”
- *SearchScreeningEvent*: 例如, “Check the showtimes for *Wonder Woman* in Paris。”

SNIPS 链接 <https://github.com/monologg/JointBERT/tree/master/data/snips>

ATIS 链接 <https://github.com/monologg/JointBERT/tree/master/data/atis>

Snips 数据集: <https://www.kaggle.com/datasets/weipengfei/atis-snips>

评估方法:

口语理解中的意图识别与槽填充任务采取多方面评价指标: 对于意图识别任务, 由于其样本相对均衡, 采取准确率 (accuracy) 作为评价指标; 对于槽填充任务, 采用实体级别的 F1 值 (F1-score) 作为评价指标; 除此之外, 本章还采用句子级别的准确率 (sentence-level accuracy) 综合评价口语理解任务完成的效果。

准确率, 即预测类别正确的样本占全部样本的比例, 计算方法如公式 2 所示。

$$\text{accuracy} = \frac{\text{预测类别正确的样本数量}}{\text{全部的样本数量}} \quad (\text{公式 2})$$

精确率也被称为查准率, 即对于某一个类别 c_i , 预测正确的样本占全部预测为 c_i 的样本的比例, 计算方法如公式 3 所示。

$$\text{precision} = \frac{1}{N} \sum_{i=1}^N \frac{\text{正确预测为 } c_i \text{ 的样本数量}}{\text{预测为 } c_i \text{ 的样本数量}} \quad (\text{公式 3})$$

召回率也被称为查全率, 即对于某一个类别 c_i , 预测正确的样本占全部标签为 c_i 的样本的比例, 计算方法如公式 4 所示。

$$\text{recall} = \frac{1}{N} \sum_{i=1}^N \frac{\text{正确预测为 } c_i \text{ 的样本数量}}{\text{标签为 } c_i \text{ 的样本数量}} \quad (\text{公式 4})$$

F1 值兼顾了精确率与召回率，即为精确率与召回率的调和平均数，计算方法如公式 5 所示。

$$F_1 - \text{score} = 2 \cdot \frac{\text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}} \quad (\text{公式 5})$$

句子级别的准确率，即为意图识别结果正确且槽填充结果全部正确的样本占全部样本的比例，计算方法如公式 6 所示。

$$\text{sent - acc} = \frac{\text{意图和槽均预测正确的样本数量}}{\text{全部的样本数量}} \quad (\text{公式 6})$$

专题 11 开放领域的中文问答系统

在 NLPCC 2018 中，发布了开放领域问答共享任务称为开放领域问答共享任务，它包括中文（前两个）和英语（后一个）的以下三个子任务：

- 基于知识的问答 (KBQA)
- 基于知识的问题生成 (KBQG)
- 基于知识的问题理解 (KBQU)

对于 KBQA 任务，我们将提供一个训练集和一个测试集。下面给出一个训练数据集的例子：

<question id="X">	你知道迪克牛仔是什么属相吗？
<answer id="X">	鼠

在训练集，问题和他们的最佳答案将提供。在测试集，将只提供问题。参赛队伍应预测测试集中每个问题的答案。提交文件的格式应遵循上述格式。如果无法预测给定问题的答案，只需将<answer id=" X ">的值设置为空字符串。KBQA 系统的质量将通过答案精确匹配来评估。

对于 KBQG 任务，我们将提供一个训练集和一个测试集。下面给出一个列车集的例子：

<triple id="X">	微软 创始人 比尔盖茨
<question id="X">	是谁创办了微软公司？

在训练集，这两个三组和他们的黄金问题将提供。在测试集中，只提供三元组。同学们可以自己讲训练集拆分一部分作为测试集。应该为测试集中的每个三元组生成一个自然语言问题，这个生成的问题可以由给定三元组的对象实体来回答。提交文件的格式应遵循上述格式。KBQG 系统的质量将由 BLEU-4 进行评估。

对于 KBQU 任务，我们将提供一个训练集和一个测试集。下面给出一个训

练集的例子:

<question id="X">	what is fight songs of Maryland
<logical form id="X">	(lambda ?x (sports.team.fight_song Maryland ?x))

在训练集中，将提供问题及其黄金逻辑形式。在测试集，将只提供问题。同学们可以自己讲训练集拆分一部分作为测试集。为测试集中的每个问题断言一个逻辑形式。提交文件的格式应遵循上述格式。KBQU 系统的质量将通过逻辑形式的精确匹配来评估。

更详细内容可参考任务文档:

<http://tcci.ccf.org.cn/conference/2018/dldoc/taskgline07.pdf>

数据集: <https://aistudio.baidu.com/datasetdetail/120603>