

2026春《自然语言处理》课程实训课题与 期末作业

敲黑板

本课程是考查课程，考虑到大家的课业压力，对课程的考核要求初步设计如下：

根据大纲要求，课程成绩分为平时成绩和期末成绩，占比分别是40%和60%，其中平时成绩40分包括：课程思政和课堂表现（课堂参与情况10分）+ 完成至少2个实训专题（提交代码+报告）（30分）； 期末成绩60分：选择如下实训专题的其中2个(与平时成绩的1个不同) 做深入研究，最终完成一份符合学术论文要求的课程报告（提交代码+课程论文）。简而言之，大家至少需要完成3个实训专题的作业，其中1个自己感觉做的最好、最有创意的专题可选为期末大作业。相关数据集下载方式将在课程群发布给大家，期末时间较为紧张，大家需要提前做好准备，尽量不要拖到最后一周。

实训专题1：汉语分词技术

汉语分词技术是中文信息处理的基础工作，本学期课程内容中我们没有专门安排分词方法的介绍，但课上所讲的方法可以应用到分词中，本专题主要考察大家的资料查阅和自学能力，课程所学方法的应用能力。同学们可以从以下几个角度来研究：

1. 使用隐马尔可夫模型进行中文分词

(1) 训练要点包括：掌握训练HMM的过程；掌握viterbi函数的定义，实现viterbi算法；对文本进行分词

(2) 具体需求：给定训练文本trainCorpus.txt，通过HMM的训练方法，得到模型，并用模型对新闻语句“深航科技攀枝花机场遇险：机腹轮胎均疑受损，跑道灯部分损坏”进行分词。

(3)实现步骤：

- a) 定义train函数，通过训练文本，计算初始概率、转移概率和发射概率，并用相应的数据结构保存（如json文件格式）
- b) 定义viterbi函数，用于实现viterbi算法
- c) 定义cut或split函数，实现分词

2. 提取文中的高频词

在HMM分词模型的基础上，对给定的文本语料(flightnews.txt)进行分词，并提取文本中出现频率最高的前10个词语。

实现步骤：

- a) 读取flightnews.txt文件
- b) 加载stopword.txt文件，对新闻内容进行分词。
- c) 提取出现频率最高的前10个词语。

特别说明:如果HMM的分词模型没有实现，或者实现效果不好，可以采用现在已有的分词工具模块，比如jieba等

3.其他分词模型的探索

如果隐马尔可夫模型的分词效果没有达到预期，而你又想在分词这个主题做更深入的算法实现，可以考虑更复杂的机器学习模型，如条件随机场或最大熵模型等，当然也可以探索基于深度学习的各种模型。建议选择此实训专题为课程期末作业的同学做深入研究。

实训专题2：汉语词性标注

参考专题1的要求，将任务转换为词性标注上，训练语料为人民日报1998年1月份的带标注语料，可选择的方法包括HMM、条件随机场等，也可以根据自己的技术基础，选择更新的模型进行训练。

除了词性标注本身任务，本专题可拓展的功能包括：命名实体识别

实训专题3： 文本向量化

1. 实现基于word2vec模型的新闻语料词向量训练

首先对2019年《人民日报》每日新闻语料进行预处理，并通过word2vec模型实现文本向量化。具体实现步骤参考：

- a) 读取txt文件格式的新闻语料库。
- b) 提取新闻文本内容进行预处理，查看数据是否存在缺失值，并进行去重操作【可选】
- c) 利用分词工具对语料进行切分（根据分词工具功能，可以针对新闻类文本特殊处理）
- d) 根据分词后的结果去停用词，并处理数据集中的无意义的词语，如"\u3000"等
- e) 保存处理后的数据集，自己实现word2vec或调用gensim库的word2vec函数训练词向量

2. 实现基于doc2vec的新闻语料段落向量训练

如果在词向量训练中采用gensim库的word2vec函数，可继续深入调研gensim库的Doc2Vec函数，训练段落向量

3. 在word2vec和doc2vec基础上，计算两个新闻文本片段的相似度

可供参考的思路：

(1)词向量方法：

a) 提取新闻文本的关键词

b)使用word2vec模型将关键词向量化，将所有关键词的向量相加，得到文本向量化表示

c) 利用文本向量表示进行文本的相似度计算(余弦相似度)

(2)利用文档向量方法doc2vec

a)对新闻文本进行停用词去除等预处理

b)将句子进行向量化，找到合适的向量代表输入文档

c)利用余弦值计算文本相似度

学有余力的同学，也可以在这个主题选择更好的模型，主要的需求是构造词向量，并计算文本相似度

实训专题4：文本分类

本专题将提供一份80万条经过脱敏处理的短信数据，其中包含大量垃圾短信信息，数据由3个字段构成，分别是“短信id”、“是否垃圾短信”(0代表常规短信，1代表垃圾短信)和“短信文本内容”。任务要求采用朴素贝叶斯模型或其他分类模型，对垃圾短信进行分类。主要步骤可包括：

1. 数据读取

2. 文本预处理。对原始数据进行预处理，如去重、脱敏和分词等操作，然后进行词频统计，分别统计垃圾短信和非垃圾短信的词频分布情况，可用相应的可视化形式呈现（如词云）。本题提供的数据量较大，有80万条，如实验条件有限，可考虑对数据进行采用，比如抽取5-10万条进行模型训练与分类

3. 分类。可采用自定义的朴素贝叶斯模型，也可以调用第三方工具，如sci-learn等库内置函数进行分类
4. 模型评价。根据划定的测试集进行预测，对比真实值与预测值，获得准确率，并进行结果分析。

实训专题5： 文本情感分析

本专题将提供一份《流浪地球》的豆瓣影评数据作为语料，完成如下两个任务：

1. 基于词典的豆瓣影评文本情感分析

除了影评数据，我们还会提供情感词典、程度副词列表、否定词列表和停用词列表，同学们可以通过如下思路和步骤来实现：

- a) 对句子进行分词，通过去除停用词，提取重要词语列表来代表句子
- b) 加载情感词典，根据程度副词、否定词出现情况，设计模型计算各个词语的情感得分情况
- c) 结合各个词语的情感得分情况，定义句子的情感得分计算模型，汇总情感词的总得分

测试语句：“电影比预期要更恢宏磅礴”、“煽情显得太尴尬”

2. 基于朴素贝叶斯算法的豆瓣影评文本情感分析

本任务将上述影评数据分积极和消极影评文本两份数据(pos.txt, neg.txt)，基于朴素贝叶斯方法进行情感分析

具体思路如下：

- a) 读取文本数据并分词，对积极词与消极词设定标签，作为特征
- b) 划分训练集和测试集

c) 构造朴素贝叶斯分类器

d) 输入评论数据进行验证

实训专题6：基于深度神经网络方法实现前述各 专题任务

考虑部分同学在深度学习方面已有较好的基础，鼓励基于自身的能力，在上述各专题任务中采用深度学习方法来实现。当然，也鼓励同学们根据自己对自然语言处理领域的了解情况，提出更有挑战的任务，比如机器翻译、对话系统等问题。

实训主题7：结合LLM的一些应用【见2026年新 增专题】

如果本身已有部分NLP基础，且在LLM方面有积累的同学，可以考虑基于LLM，如 豆包、DeepSeek、百度文心一言、讯飞星火等大模型的API，构造一些NLP的应用，如对话系统之类。